

Análise de Artigos Científicos sobre Computação Quântica com PLN

Lucas de Oliveira Fratus (RA: 134698)
Matheus Cenerini Jacomini (RA: 134700)

Introdução à Inteligência Artificial
Universidade Estadual de Maringá
Departamento de Informática

29 de junho de 2026

Sumário

Introdução

Fundamentação

Materiais e Métodos

Fonte dos Dados

Visualizações

Demonstração

Avaliação

Conclusões

Referências

Introdução

Contexto

Artigos científicos em PDF possuem grande volume de texto, estruturas distintas e informações distribuídas em seções como resumo, introdução, metodologia e conclusão.

Problema tratado

- ▶ Extrair automaticamente informações relevantes de artigos científicos.
- ▶ Identificar objetivo, problema, método e contribuições.
- ▶ Organizar os resultados para avaliação e representação em ontologia.

Tema do corpus

Computação Quântica, com foco em aplicações, algoritmos, segurança, IA e modelos híbridos.

Modelagem do Problema

Entrada

- ▶ 12 artigos científicos em PDF;
- ▶ tema: *Quantum Computing*;
- ▶ textos extraídos dos documentos;
- ▶ seções e referências bibliográficas.

Saída esperada

- ▶ termos, bigramas e trigramas frequentes;
- ▶ objetivo, problema, método e contribuições;
- ▶ ontologia em JSON-LD;
- ▶ métricas de desempenho;
- ▶ gráficos e observações adicionais.

Fundamentação: PLN

Processamento de Linguagem Natural

PLN permite processar textos escritos em linguagem humana por meio de técnicas computacionais de limpeza, segmentação, normalização e análise.

Técnicas usadas

- ▶ extração de texto de PDF;
- ▶ tokenização;
- ▶ remoção de stopwords;
- ▶ lematização;
- ▶ bag of words;
- ▶ n-gramas.

Fundamentação: Extração de Informações

Ideia central

A extração de informações busca localizar trechos específicos em textos não estruturados. Neste trabalho, as informações são divididas em quatro categorias.

Categoria	Pergunta respondida
Objetivo	O que o artigo pretende fazer?
Problema	Qual desafio ou limitação motivou o estudo?
Método	Como os autores desenvolveram ou avaliaram a proposta?
Contribuições	O que o artigo afirma entregar de relevante?

Fundamentação: Avaliação

Métricas adotadas

Como o sistema recupera sentenças relevantes, foram usadas métricas semelhantes as de Recuperação de Informação.

$$Precisão = \frac{TP}{TP + FP} \quad Cobertura = \frac{TP}{TP + FN}$$

- ▶ **TP**: sentença relevante encontrada corretamente;
- ▶ **FP**: sentença extraída, mas não relevante para a categoria;
- ▶ **FN**: sentença relevante do gabarito que não foi encontrada;
- ▶ **Taxa FP**: $1 - Precisão$;
- ▶ **Taxa FN**: $1 - Cobertura$.

Materiais e Métodos

Linguagem e ambiente

- ▶ Python 3;
- ▶ ambiente virtual;
- ▶ execução por terminal;
- ▶ organização em etapas independentes.


Arquivos principais

- ▶ `preprocessamento.py`
- ▶ `extracao_informacoes.py`
- ▶ `ontologia.py`
- ▶ `avaliacao.py`
- ▶ `visualizacao.py`

Bibliotecas utilizadas

- ▶ `pypdf`: leitura inicial dos PDFs;
- ▶ `pdfminer.six`: extração alternativa de texto;
- ▶ `nltk`: tokenização, stopwords e lematização;
- ▶ `re`: expressões regulares;
- ▶ `json`, `csv`, `pathlib`, `os`;
- ▶ `difflib`: comparação textual;
- ▶ `matplotlib`: gráficos;
- ▶ `wordcloud`: nuvem de palavras;
- ▶ `numpy`: apoio numérico.

Pipeline Geral



Cada etapa gera arquivos intermediários em resultados/.

Estrutura do Projeto

Entrada

artigos/ 12 artigos científicos
usados no corpus principal.

Código-fonte

```
src/preprocessamento.py  
src/extracao_informacoes.py  
src/ontologia.py  
src/avaliacao.py  
src/visualizacao.py
```

Resultados intermediários

```
resultados/etapa1_resultados.json  
resultados/etapa2_resultados.json  
resultados/etapa4_metricas.json  
resultados/etapa4_detalhes.csv
```

Saídas finais

```
ontologia/ontologia_corpus.jsonld  
resultados/observacoes/  
  
Gráficos, nuvem de palavras,  
heatmap e análise temporal.
```

Etapa 1: Pre-processamento

Operações realizadas

- ▶ leitura dos PDFs;
- ▶ extração do corpo textual;
- ▶ separacao da seção de referências;
- ▶ limpeza de caracteres;
- ▶ tokenização;
- ▶ remoção de stopwords;
- ▶ lematização;
- ▶ união de expressões compostas.

Saidas

- ▶ quantidade de tokens por artigo;
- ▶ referências extraídas;
- ▶ palavras mais frequentes;
- ▶ bigramas;
- ▶ trigramas;
- ▶ arquivo
`etapa1_resultados.json`.

Exemplos de termos

quantum, model, state, gate,
circuit

Etapa 2: Extração de Informações

Estratégia

A extração combina nomes de seções, expressões regulares, palavras-chave e filtros para selecionar sentenças candidatas.

```
CATEGORIAS = [  
    "objetivo",  
    "problema",  
    "metodo",  
    "contribuicoes"  
]  
  
# Exemplos de padroes linguisticos:  
# objetivo: "this paper proposes", "this study aims"  
# problema: "however", "challenge", "limitation", "gap"  
# metodo: "we use", "dataset", "experiment", "implemented"  
# contribuicoes: "our contributions", "we propose", "novel"
```

O resultado é salvo em resultados/etapa2_resultados.json.

Etapa 3: Ontologia

Representação em JSON-LD

Os dados extraídos foram serializados em uma ontologia simples para representar o corpus e seus artigos.

Classe Corpus

- ▶ conjunto de artigos;
- ▶ termos mais frequentes;
- ▶ estatísticas;
- ▶ visualizações.

Classe Artigo Científico

- ▶ identificador;
- ▶ objetivo;
- ▶ problema;
- ▶ metodologia;
- ▶ contribuições;
- ▶ referências.

Saída: `ontologia/ontologia_corpus.jsonld`.

Etapa 4: Avaliação

Comparação com gabarito manual

As sentenças extraídas automaticamente foram comparadas com um gabarito manual preenchido para os 12 artigos.

```
similaridade = SequenceMatcher(  
    None,  
    sentenca_extraida,  
    sentenca_gabarito  
) .ratio()
```

- ▶ pequenas diferenças de formatação do PDF são normalizadas;
- ▶ cada categoria é avaliada separadamente;
- ▶ as métricas seguem os conceitos de precisão e cobertura.

Fonte dos Dados

Corpus principal

Foram selecionados 12 artigos científicos sobre *Quantum Computing*, obtidos a partir de busca na base Scopus.

Critérios gerais

- ▶ artigos em PDF;
- ▶ publicações recentes;
- ▶ foco em computação quântica e áreas relacionadas;
- ▶ diversidade de subtemas: IA, NLP, blockchain, IoT, cibersegurança, compilação quântica, QFT, edge-cloud e simulação de materiais.


Pasta utilizada

artigos/


Artigos do Corpus

N.	Tema resumido	Ano
1	Revisão sistemática sobre IA e Computação Quântica	2026
2	QRNN para rotulação sequencial em PLN	2026
3	Semi-quantum blockchain	2026
4	Intrusion Detection em IoT com modelos quânticos	2026
5	CBQC versus MBQC	2026
6	Compilacao distribuida e reordenacao de portas	2026
7	Arquiteturas modulares e emaranhamento	2025
8	Simulacao de corrosao com computação quântica	2025
9	Compilacao ótima de QFT em DPQA	2025
10	Transfer learning quantico para cibersegurança	2026
11	QRL e Golden Jackal Optimization para edge-cloud	2026
12	AI-QRCPS para sistemas ciberfísicos	2026


Palavras Mais Citadas




Nuvem de Palavras




Técnicas Mais Mencionadas




Distribuição de Termos por Artigo



Evolução Temporal dos Termos



Termos Relacionados a Trabalhos Futuros




Demonstração Prática

Resultados da Avaliação

Categoria	TP	FP	FN	Precisão	Cobertura	Taxa FP	Taxa FN
Objetivo	20	13	29	0.6061	0.4082	0.3939	0.5918
Problema	20	28	61	0.4167	0.2469	0.5833	0.7531
Método	6	42	134	0.1250	0.0429	0.8750	0.9571
Contribuições	10	0	63	1.0000	0.1370	0.0000	0.8630
Global	56	83	287	0.4029	0.1633	0.5971	0.8367

Gráfico da Avaliação



Análise dos Resultados

Pontos positivos

- ▶ objetivos foram recuperados com melhor precisão;
- ▶ contribuições extraídas tiveram poucos falsos positivos;
- ▶ o pipeline completo ficou funcional;

Dificuldades

- ▶ metodos aparecem em seções muito longas;
- ▶ há diferenças grandes de formato entre artigos;
- ▶ PDFs geram ruídos, quebras e textos colados;
- ▶ objetivo, método e contribuicao podem usar expressões parecidas;

Interpretação das Métricas

Precisão

Mede a proporção das sentenças extraídas que realmente estavam corretas.

Cobertura

Mede a proporção das sentenças relevantes do gabarito que foram encontradas.

Conclusão da avaliação

- ▶ O sistema é mais conservador em contribuições: quase não erra, mas encontra pouco.
- ▶ Objetivo é a categoria mais equilibrada.
- ▶ Método apresenta baixa cobertura porque depende de descrições longas e variadas.

Conclusões

Resultados alcançados

- ▶ leitura e processamento de PDFs;
- ▶ extração de termos e n-gramas;
- ▶ identificação de informações estruturadas;
- ▶ criação de uma ontologia JSON-LD;
- ▶ avaliação quantitativa;
- ▶ geração de gráficos e observações.

Referências

- [1] IGARASHI, Wagner. *Processamento de Linguagem Natural*. Slides da disciplina *Introdução à Inteligência Artificial*. Universidade Estadual de Maringá, Departamento de Informática, 2026.
- [2] PYPDF. *pypdf documentation*. Disponível em: <https://pypdf.readthedocs.io>.
- [3] PDFMINER.SIX. *pdfminer.six documentation*. Disponível em: <https://pdfminersix.readthedocs.io>.
- [4] NLTK PROJECT. *NLTK documentation*. Disponível em: <https://www.nltk.org>.
- [5] W3C. *JSON-LD 1.1: A JSON-based Serialization for Linked Data*. Disponível em: <https://www.w3.org/TR/json-ld11/>.
- [6] MATPLOTLIB. *Matplotlib documentation*. Disponível em: <https://matplotlib.org>.
- [7] MUELLER, A. *wordcloud for Python*. Disponível em: https://amueller.github.io/word_cloud/.
- [8] ELSEVIER. *Scopus*. Disponível em: <https://www.scopus.com>.